

**Analisis Performa dan Evaluasi Komparatif
Arsitektur *Deep Learning* untuk Deteksi
Kerusakan dan Cacat Permukaan Jalan di
Indonesia**

Proposal Tugas Akhir

Kelas TA 1

Faaris Khairrudin

NIM: 103052300115



Program Studi Sarjana Sains Data

Fakultas Informatika

Universitas Telkom

Bandung

2026

Lembar Persetujuan

Analisis Performa dan Evaluasi Komparatif Arsitektur *Deep Learning* untuk Deteksi Kerusakan dan Cacat Permukaan Jalan di Indonesia

Performance Analysis and Comparative Evaluation of Deep Learning Architectures for Road Damage and Defect Detection in Indonesia

**Faaris Khairrudin
NIM: 103052300115**

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Sains Data
Fakultas Informatika Universitas Telkom

Bandung, 4 September 2026
Menyetujui

Calon Pembimbing 1

Dr. GAMMA KOSALA, S.Si
NIP: 26920005

Abstrak

Infrastruktur jalan yang memadai merupakan prasyarat krusial bagi mobilitas dan keselamatan transportasi. Inspeksi kerusakan jalan secara manual dinilai tidak efisien, padat karya, dan rentan terhadap subjektivitas. Meskipun algoritma *deep learning* dari keluarga YOLO telah terbukti efektif dalam otomasi deteksi kerusakan jalan, implementasinya di dunia nyata masih dihadapkan pada beberapa tantangan utama: tingginya tingkat kesalahan deteksi (*false positive*) akibat objek pengecoh visual seperti penutup saluran air dan tambalan aspal, fenomena *domain shift* yang menurunkan akurasi model global saat diterapkan pada karakteristik jalan lokal di Indonesia, serta besarnya beban komputasi model untuk skenario pengawasan *real-time*.

Penelitian ini bertujuan untuk melakukan evaluasi komparatif terhadap arsitektur YOLO *baseline*, YOLO modifikasi (*lightweight*), dan iterasi YOLO terbaru guna menemukan titik optimal antara akurasi deteksi dan efisiensi komputasi. Pelatihan model dilakukan menggunakan dataset global N-RDD2024 (subset Asia) yang secara eksplisit memuat anotasi kelas kerusakan dan kelas pengecoh. Kinerja ketepatan deteksi model dievaluasi menggunakan metrik mAP50 dan F1-Score, sementara kelayakan implementasi *real-time* dianalisis melalui uji keseimbangan kinerja (*trade-off*) berdasarkan metrik GFLOPs, ukuran parameter, dan kecepatan inferensi (FPS). Model terbaik dari hasil komparasi tersebut kemudian dievaluasi lebih lanjut secara *zero-shot* menggunakan data primer tak terlihat (*unseen data*) dari jalan raya Bandung, Indonesia.

Pengujian tahap akhir ini dirancang untuk mengukur tingkat kemampuan generalisasi dan besaran *domain gap* secara kuantitatif tanpa melalui proses *fine-tuning*. Hasil dari penelitian ini diharapkan dapat menghasilkan model deteksi kerusakan jalan yang komprehensif, terbukti ringan untuk perangkat komputasi terbatas, presisi dalam membedakan kerusakan dari objek pengecoh, serta memiliki ketangguhan adaptasi yang tinggi terhadap kompleksitas visual infrastruktur jalanan di Indonesia.

Kata Kunci: Deteksi Kerusakan Jalan, YOLO, *Domain Shift*, *Zero-Shot Inference*, N-RDD2024, *Lightweight Model*.

Daftar Isi

Abstrak	i
Daftar Isi	ii
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	5
1.5 Rencana Kegiatan	5
1.6 Jadwal Kegiatan	6
II Kajian Pustaka	8
2.1 Kerusakan Permukaan Jalan dan Dataset N-RDD2024	8
2.2 <i>You Only Look Once</i> (YOLO)	9
2.3 Modifikasi Arsitektur YOLO untuk Efisiensi	11
2.4 <i>Domain Shift</i> dan Evaluasi <i>Zero-Shot</i>	12
2.5 Penelitian Terkait	13
III Metodologi dan Desain Sistem	15
3.1 Eksplorasi Data	15
3.1.1 Akuisisi Dataset	15
3.1.2 Visualisasi Data	15
3.2 Alur Penelitian	19
3.3 Rancangan Arsitektur Model	21
3.4 Evaluasi Performa Model	22
3.4.1 <i>Confusion Matrix</i> (TP, FP, FN)	22
3.4.2 <i>Precision, Recall</i> , dan <i>F1-Score</i>	23
3.4.3 <i>Intersection over Union</i> (IoU) dan <i>Mean Average Precision</i> (mAP)	23
3.4.4 Metrik Efisiensi Komputasi	24
3.5 Skenario Penelitian	24
3.5.1 Skenario 1: Evaluasi Kinerja pada Domain Sumber dan Analisis Kelas Pengecoh	24

3.5.2	Skenario 2: Analisis Keseimbangan Kinerja (<i>Trade-Off</i>) dan Kelayakan <i>Real-Time</i>	25
3.5.3	Skenario 3: Uji Ketangguhan Lintas Domain (<i>Zero-Shot Inference</i>)	25
Daftar Pustaka		26
Lampiran		28

Bab I

Pendahuluan

1.1 Latar Belakang

Infrastruktur jalan merupakan fondasi utama pengembangan ekonomi dan mobilitas suatu bangsa. Kondisi jaringan jalan yang baik menjadi prasyarat bagi urbanisasi, pertumbuhan industri, dan pemenuhan kebutuhan transportasi masyarakat [1, 2]. Namun, seiring dengan meningkatnya beban lalu lintas dan paparan faktor lingkungan, kerusakan jalan berupa retak dan lubang (*pothole*) tidak hanya menurunkan efisiensi perjalanan, tetapi juga meningkatkan risiko kecelakaan dan mengancam keselamatan pengemudi maupun penumpang [3].

Persoalan kerusakan jalan memiliki dimensi yang lebih kritis di Indonesia. Hugo dkk. mencatat bahwa penyebab utama kerusakan jalan di Indonesia meliputi kendaraan yang melebihi batas muatan, kondisi iklim tropis dengan curah hujan tinggi, drainase jalan yang buruk, kondisi tanah yang tidak stabil, serta kualitas material perkerasan yang tidak memadai [4]. Akibatnya, Indonesia secara konsisten menghadapi kecelakaan lalu lintas, kemacetan berkepanjangan, dan kerusakan kendaraan yang berkaitan langsung dengan kondisi jalan yang rusak [4]. Kusumah dkk. menunjukkan bahwa kerusakan jalan yang parah memaksa pengemudi untuk lebih waspada, dan kondisi ini secara langsung berpotensi menimbulkan kecelakaan serta tabrakan antar kendaraan di jalan raya Indonesia [5].

Secara tradisional, pemantauan kondisi jalan dilakukan melalui inspeksi manual menggunakan patroli kendaraan, pencatatan foto, serta tenaga pengawas lapangan. Metode ini dinilai tidak efisien, membutuhkan sumber daya yang besar, dan rentan terhadap subjektivitas penilaian [3]. Hosseini dan Smadi menegaskan bahwa tingkat akurasi prediksi kondisi jalan secara langsung memengaruhi proses pengambilan keputusan dalam sistem manajemen pemeliharaan infrastruktur [6]. Selain itu, selama proses inspeksi berlangsung, kendaraan patroli dan petugas sering kali harus menduduki badan jalan sehingga berpotensi menimbulkan kemacetan dan risiko keselamatan tambahan [3]. Hugo dkk. juga menekankan bahwa metode konvensional ini bersifat *labor-intensive*, berbiaya tinggi, dan tidak memiliki skalabilitas yang memadai untuk mencakup jaringan jalan nasional yang luas [4].

Perkembangan pesat *deep learning* dalam dekade terakhir telah membuka peluang baru untuk otomasi deteksi kerusakan jalan. Berbeda dengan metode tradisional yang bergantung pada ekstraksi fitur manual, algoritma *deep learning* mampu secara otomatis mengidentifikasi lokasi, jenis, dan batas kerusakan dalam citra secara cepat dan akurat [1]. Mandal dkk. melakukan analisis komparatif terhadap berbagai kerangka *deep learning* untuk klasifikasi distress perkerasan, menemukan bahwa arsitektur YOLO mencapai F1-Score tertinggi sebesar 0,5814 dan 0,5751 pada dua dataset pengujian yang berbeda, melampaui CenterNet dan EfficientDet [7]. Sejak saat itu, berbagai varian arsitektur berbasis YOLO telah dikembangkan khusus untuk deteksi kerusakan jalan, termasuk RDD-YOLO [3], YOLOv8-PD [1], YOLO-RD [8], YOLO-LWD [9], dan YOLO-LWNet [10], yang masing-masing mengusulkan modifikasi arsitektur untuk meningkatkan presisi dan efisiensi komputasi.

Pengembangan model-model tersebut sebagian besar mengandalkan *Road Damage Dataset 2022* (RDD2022), sebuah dataset *benchmark* multi-nasional yang dikembangkan oleh Arya dkk. melalui *Crowdsensing-based Road Damage Detection Challenge* (CRDDC2022). Dataset ini terdiri atas 47.420 citra jalan dari enam negara (Jepang, India, Ceko, Norwegia, Amerika Serikat, dan China), dengan lebih dari 55.000 instans anotasi *bounding box* yang mencakup empat kelas kerusakan struktural: retak memanjang (D00), retak melintang (D10), retak buaya (D20), dan lubang jalan (D40) [11]. Pada kompetisi CRDDC2022, model terbaik berhasil mencapai F1-Score sebesar 0,770 untuk keenam negara secara agregat, dengan performa terbaik pada dataset Amerika Serikat ($F1 = 0,844$) [11].

Namun, di balik capaian tersebut, terdapat dua kesenjangan (*research gap*) yang signifikan. Pertama, masalah *domain shift*: model yang dilatih pada data dari satu negara mengalami degradasi performa yang nyata saat diuji pada data dari negara lain, suatu fenomena yang telah dilaporkan sejak RDD2019 dan dikonfirmasi kembali pada CRDDC2022 [11]. Fakta ini menjadi sangat relevan bagi Indonesia, yang sama sekali tidak terwakili dalam RDD2022. Hugo dkk. melaporkan bahwa penerapan EfficientDet-D0 yang dilatih pada data jalan Indonesia dengan 3.321 citra hanya mampu mencapai F1-Score terbaik sebesar 59,7%, yang mereka kaitkan dengan kompleksitas fitur kerusakan jalan lokal dan tantangan generalisasi pada data yang belum pernah dilihat [4]. Di sisi lain, karena kelas lubang jalan secara inheren memiliki jumlah sampel yang sangat sedikit (*class imbalance*), tetap diperlukan optimasi fungsi *loss* khusus seperti *Focal Loss* agar model sensitif terhadap kelas minoritas tersebut [4, 12].

Kedua, terdapat masalah *false positive* yang bersumber dari elemen permukaan jalan non-kerusakan yang memiliki kemiripan visual tinggi dengan kerusakan struktural. Matouq dkk. menyatakan secara eksplisit bahwa mayoritas algoritma berbasis citra yang berfokus pada deteksi lubang jalan gagal mempertimbangkan secara memadai kemiripan visual antara *pothole*, *manhole*,

dan *patch*, serta menegaskan adanya kebutuhan mendesak akan dataset pelatihan dan metodologi yang lebih baik untuk mengatasi tantangan ini secara efektif [13, 9]. Konsekuensinya tercermin pada hasil Zeng dan Zhong, yang menemukan bahwa akurasi deteksi kelas D40 (*pothole*) pada YOLOv8-PD hanya mencapai 53,1% dan mengakibatkan *missed detection* yang berulang [1]. Rendahnya performa pada kelas lubang jalan ini merupakan masalah sistemik yang disebabkan oleh karakteristik objeknya yang tidak beraturan, ukurannya yang kecil, serta minimnya jumlah sampel latih jika dibandingkan dengan kelas kerusakan lain [1]. Sejalan dengan itu, Kaya dan Çodur mempublikasikan dataset N-RDD2024, sebuah versi perluasan dari RDD2022 yang mempertahankan keenam negara asal tetapi memperluas cakupan anotasi menjadi 10 kelas cacat permukaan, meliputi retak yang telah diperbaiki (D30), penurunan visibilitas penyeberangan pejalan kaki (D50), penurunan visibilitas marka lajur (D60), penutup *manhole* (D70), segmen jalan yang ditambal (*patchy road*, D80), dan *rutting* (D90) [14]. Dalam konteks penelitian ini, kelas D70 dan D80 secara khusus diadopsi sebagai kelas pengecoh (*distractor classes*) selama pelatihan, mengacu pada temuan Matouq dkk. yang mengidentifikasi keduanya sebagai sumber utama *false positive* [13]. Selain itu, penutup *manhole* yang tidak rata (D70) dan tambalan aspal yang menonjol (D80) juga berpotensi menjadi *hazard* tersendiri bagi pengguna jalan, khususnya pengendara sepeda motor, sehingga kemampuan model dalam mengenali kedua kelas ini memberikan nilai tambah praktis pada sistem deteksi yang dikembangkan.

Berdasarkan tinjauan terhadap kondisi penelitian yang ada, terdapat celah yang belum terjawab: belum ada studi yang secara sistematis mengevaluasi dan membandingkan performa berbagai arsitektur *deep learning* menggunakan dataset N-RDD2024 dengan anotasi kelas pengecoh (kelas D70 dan D80), sekaligus mengukur secara eksplisit *domain gap* yang terjadi ketika model tersebut diuji pada kondisi jalan nyata di Indonesia melalui evaluasi *zero-shot*. Padahal, karakteristik jalan Indonesia seperti tekstur aspal, pola retak, dan distribusi infrastruktur permukaan jalan (seperti *manhole* dan tambalan) memiliki keunikan lokal yang secara langsung memengaruhi performa model yang dilatih pada dataset global [11, 4]. Oleh karena itu, penelitian ini dirancang untuk mengisi kesenjangan tersebut melalui analisis komparatif arsitektur *deep learning* secara terstruktur dengan mengintegrasikan kelas pengecoh dari N-RDD2024 dan menerapkan optimasi fungsi *loss* untuk mengatasi ketimpangan distribusi kelas. Lebih lanjut, penelitian ini juga akan mengukur *generalization gap* ke domain jalan Indonesia secara kuantitatif, serta mengevaluasi *trade-off* antara akurasi dan efisiensi komputasi guna memastikan kelayakannya untuk diimplementasikan pada perangkat komputasi terbatas.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dirumuskan ke dalam pertanyaan berikut:

1. Bagaimana performa deteksi model *deep learning* ketika dilatih menggunakan dataset N-RDD2024 yang memuat kelas kerusakan dan kelas pengecoh?
2. Bagaimana performa dan kelayakan model untuk skenario *real-time* pada perangkat komputasi terbatas ditinjau dari efisiensi komputasi?
3. Bagaimana tingkat *domain gap* atau kemampuan generalisasi model terbaik yang dilatih menggunakan dataset global N-RDD2024 ketika diuji secara langsung (*zero-shot*) pada dataset primer kondisi jalan raya nyata di Indonesia?

1.3 Tujuan Penelitian

Sejalan dengan rumusan masalah di atas, tujuan dari penelitian ini dirancang secara berkesinambungan untuk mencapai target berikut:

1. Mengevaluasi dan membandingkan performa deteksi dari arsitektur YOLO *baseline*, YOLO modifikasi, dan YOLO terbaru dengan melatihnya menggunakan dataset global N-RDD2024. Evaluasi ini dilakukan untuk mengukur tingkat akurasi (mAP) setiap arsitektur dalam mengenali kelas kerusakan jalan utama, sekaligus menganalisis ketangguhannya dalam menekan tingkat kesalahan deteksi (*false positive*) yang dipicu oleh kemiripan visual dengan objek pengecoh (seperti penutup saluran air dan tambalan jalan).
2. Menganalisis kelayakan implementasi *real-time* dan efisiensi komputasi dari model yang telah dilatih dengan membandingkan capaian akurasi terhadap beban komputasi jaringan, yang mencakup kecepatan inferensi dalam FPS, ukuran parameter, serta GFLOPs. Analisis keseimbangan kinerja (*trade-off*) ini bertujuan untuk menemukan titik optimal guna menentukan satu model terbaik yang tidak hanya presisi secara deteksi, tetapi juga terbukti ringan dan layak untuk diimplementasikan pada perangkat dengan sumber daya komputasi terbatas.
3. Mengukur ketangguhan generalisasi dan tingkat *domain gap* dari model terbaik yang terpilih melalui pengujian secara langsung (*zero-shot*) menggunakan data primer citra jalan raya di wilayah Bandung, Indonesia, tanpa melakukan pelatihan ulang (*fine-tuning*). Tahap evaluasi akhir ini akan membuktikan secara kuantitatif seberapa tangguh arsitektur tersebut mampu beradaptasi, sekaligus mengukur tingkat penurunan

akurasi yang terjadi akibat perbedaan karakteristik visual antara jalan raya global dengan kompleksitas nyata infrastruktur jalanan lokal.

1.4 Batasan Masalah

Batasan-batasan yang diterapkan pada penelitian ini adalah sebagai berikut:

1. Pelatihan model (*global benchmarking*) dibatasi hanya menggunakan subset dataset [N-RDD2024](#) yang bersumber dari negara Asia (India, Tiongkok, dan Jepang) dengan total 10.395 citra, guna mewakili karakteristik jalan yang paling mendekati topologi wilayah Asia.
2. Deteksi difokuskan pada pengenalan anomali permukaan jalan raya aspal atau beton. Kelas yang dideteksi secara spesifik meliputi empat kelas kerusakan struktural utama (retak memanjang, retak melintang, retak buaya, dan lubang jalan), serta dua kelas pengecoh visual (penutup saluran dan jalan bertambal).
3. Penelitian ini berfokus pada tugas deteksi objek (lokalisasi serta klasifikasi). Penelitian ini tidak mencakup estimasi tingkat keparahan (*severity*).
4. Evaluasi *zero-shot* dan pengumpulan data primer dibatasi pada wilayah Bandung yang diambil pada kondisi siang hari (visibilitas normal) guna mengisolasi variabel pencahayaan.
5. Pengujian efisiensi komputasi terkait kelayakan implementasi pada perangkat komputasi terbatas (*edge/mobile devices*) dievaluasi menggunakan GPU kelas menengah, dan tidak mencakup tahap *deployment (build)* menjadi aplikasi lunak siap pakai.

1.5 Rencana Kegiatan

Rencana kegiatan adalah penjelasan mengenai rencana langkah-langkah yang akan dilakukan dalam pengerjaan Tugas Akhir yang memuat:

1. **Studi Literatur Terkait dengan Deteksi Kerusakan Jalan**
Pada tahapan ini, penulis mengamati terkait metode-metode dan arsitektur *deep learning* terbaru berbasis YOLO, penerapan kelas pengecoh untuk mengurangi tingkat *false positive*, dan penyelesaian masalah *domain shift*. Penulis akan menganalisis performa dari metode-metode tersebut dan merancang skenario evaluasi yang paling sesuai.
2. **Pengumpulan dan Prapemrosesan Data**
Dataset yang digunakan adalah dataset sekunder dan dataset primer. Dataset sekunder menggunakan N-RDD2024 yang memuat anotasi kerusakan jalan dan cacat permukaan. Dataset primer merupakan citra

kondisi jalan nyata di Indonesia yang dikumpulkan di wilayah Bandung. Tahapan ini juga mencakup penyesuaian format agar siap digunakan untuk pelatihan model.

3. Perancangan Skenario Evaluasi Model

Penulis merancang arsitektur model *baseline* dari keluarga algoritma YOLO beserta model modifikasinya. Skenario penelitian dirancang secara terstruktur, yang difokuskan pada pengukuran standar performa model menggunakan dataset multinasional N-RDD2024 (*global benchmarking*), dan dilanjutkan dengan pengujian kemampuan generalisasi model secara langsung pada citra jalan lokal di Indonesia melalui evaluasi *zero-shot*.

4. Pelatihan dan Implementasi Model

Penulis mengimplementasikan kode program untuk melatih model menggunakan dataset N-RDD2024. Tahapan ini mencakup penerapan strategi optimasi fungsi *loss* (seperti *Focal Loss*) untuk menangani ketimpangan distribusi kelas. Penulis memastikan kode berjalan dengan benar untuk proses ekstraksi fitur, pelatihan, dan inferensi.

5. Pengujian dan Analisis Hasil Evaluasi

Penulis melakukan evaluasi terhadap model di seluruh skema penelitian. Model akan dinilai menggunakan metrik akurasi (*Precision*, *Recall*, *mAP*) dan metrik efisiensi komputasi (FPS, Parameter, GFLOPs). Penulis juga melakukan *error analysis* untuk melihat tingkat keberhasilan model membedakan lubang jalan asli dengan objek pengecoh.

6. Penyusunan Laporan

Penulis mendokumentasikan hasil performa dari seluruh skema eksperimen. Selain itu, penulis menulis analisis komparatif terkait *trade-off* akurasi dan efisiensi komputasi yang telah didapatkan, serta analisis *generalization gap* model ketika dihadapkan pada data jalan Indonesia (*unseen data*).

1.6 Jadwal Kegiatan

Agar pelaksanaan penelitian dapat berjalan secara terstruktur, disusunlah jadwal kegiatan per bulan sebagai berikut:

Tabel 1.1: Jadwal kegiatan proposal tugas akhir


No	Kegiatan	Bulan ke-																							
		1				2				3				4				5				6			
1	Kajian Pustaka Terkait Deteksi Kerusakan Jalan																								
2	Pengumpulan dan Prapem- rosesan Data (N-RDD2024 dan data lokal)																								
3	Perancangan Skenario Evalua- si Model (global benchmarking dan zero-shot)																								
4	Pelatihan dan Implementasi Model Deteksi Berdasarkan YOLO																								
5	Pengujian dan Analisis Hasil Evaluasi (akura- si dan efisiensi komputasi)																								
6	Penyusunan La- poran																								

Bab II

Kajian Pustaka

2.1 Kerusakan Permukaan Jalan dan Dataset N-RDD2024

Kerusakan permukaan jalan merupakan indikator utama dari penurunan kualitas perkerasan infrastruktur transportasi yang berdampak langsung pada keselamatan pengguna jalan. Secara umum, kerusakan jalan struktural diklasifikasikan ke dalam empat kategori utama, yaitu retak memanjang (*longitudinal crack*/D00), retak melintang (*transverse crack*/D10), retak buaya (*alligator crack*/D20), dan lubang jalan (*pothole*/D40). Klasifikasi standar ini menjadi landasan dalam pengembangan *Road Damage Dataset 2022* (RDD2022), sebuah dataset global yang mengumpulkan puluhan ribu citra jalan dari berbagai negara untuk mendorong pengembangan deteksi jalan otomatis [11].



Gambar 2.1: Contoh kerusakan jalan pada RDD2022 (D00, D10, D20, D40)

Meskipun RDD2022 telah memberikan kontribusi besar, dataset ini memiliki keterbatasan karena hanya berfokus pada kerusakan struktural utama dan mengabaikan elemen permukaan jalan lain yang memiliki kemiripan visual. Matouq dkk. menemukan bahwa mayoritas sistem deteksi kerusakan jalan sering kali gagal dan menghasilkan tingkat *false positive* yang tinggi karena algoritma tidak mampu membedakan lubang jalan asli dengan elemen infrastruktur lain seperti penutup saluran air (*manhole*) dan tambalan aspal (*patching*) [13]. Hal ini diperkuat oleh temuan Shi, yang mengonfirmasi bahwa penutup saluran air sangat sering dideteksi secara keliru sebagai lubang jalan, sehingga objek pengecoh tersebut mutlak perlu dianotasi secara terpisah saat melatih model

[9]. Merespons tantangan tersebut, Kaya dan Çodur memperkenalkan dataset N-RDD2024, sebuah perluasan dari RDD2022 yang menambahkan 10 kelas anomali dan cacat permukaan, termasuk kelas penutup saluran air (D70) dan jalan bertambal (D80) [14]. Dalam konteks deteksi objek, kelas-kelas tambahan ini sangat krusial untuk difungsikan sebagai kelas pengecoh. Dengan melatih model untuk mengenali kelas D70 dan D80 secara eksplisit bersamaan dengan kelas kerusakan asli, model dapat belajar membedakan fitur visual yang mirip sehingga mampu menekan tingkat kesalahan deteksi di kondisi jalan nyata [13, 9].

Di sisi lain, pemanfaatan kelas yang beragam memunculkan tantangan baru berupa ketimpangan distribusi jumlah sampel latih (*class imbalance*). Pada jalanan nyata, kerusakan berupa lubang jalan (*pothole*) secara inheren memiliki frekuensi kemunculan yang jauh lebih sedikit dibandingkan dengan retakan memanjang atau melintang. Zeng dan Zhong membuktikan bahwa ketimpangan ini menyebabkan akurasi deteksi kelas lubang jalan (D40) pada model standar seperti YOLOv8 sering kali menjadi yang paling rendah, yang berujung pada terjadinya *missed detection* (kegagalan deteksi) yang berulang [1]. Oleh karena itu, arsitektur *deep learning* yang digunakan memerlukan pendekatan modifikasi fungsi kerugian (*loss function*), seperti *Focal Loss*, guna memberikan pembobotan yang lebih besar secara adaptif pada kelas minoritas yang sulit dikenali, sehingga sensitivitas model terhadap kelas lubang jalan dapat tetap terjaga [12].


2.2 *You Only Look Once* (YOLO)

Algoritma *You Only Look Once* (YOLO) merupakan salah satu terobosan paling signifikan dalam bidang visi komputer yang diklasifikasikan sebagai detektor objek satu tahap (*one-stage detector*) [15]. Berbeda dengan algoritma dua tahap (*two-stage detector*) yang memerlukan proses pembuatan proposal wilayah (*region proposal*) secara terpisah, YOLO mengubah rumusan masalah deteksi objek menjadi sebuah masalah regresi *end-to-end* [15, 3]. Pendekatan ini memungkinkan jaringan saraf tiruan (*neural network*) tunggal untuk memprediksi probabilitas kelas dan koordinat kotak pembatas (*bounding box*) secara serentak dalam satu kali komputasi maju (*single forward pass*), sehingga menghasilkan kecepatan inferensi yang sangat tinggi [15].

Sejak pertama kali diperkenalkan oleh Joseph Redmon dkk. melalui iterasi YOLOv1, algoritma ini terus mengalami evolusi struktural yang pesat [15]. Redmon dkk. kemudian mengembangkan YOLOv2 (juga dikenal sebagai YOLO9000) dan YOLOv3, yang membawa peningkatan signifikan pada kemampuan deteksi objek melalui pengenalan jaringan residual, *Spatial Pyramid Pooling* (SPP), dan *Cross-Stage Partial Networks* (CSPNet) [16, 17]. Evolusi arsitektur ini kemudian dilanjutkan oleh Bochkovskiy dkk. melalui peluncuran YOLOv4 pada tahun 2020, yang mengkonsolidasikan berbagai teknik optimasi

mutakhir, termasuk augmentasi data *Mosaic* dan modul atensi spasial, guna menawarkan detektor objek yang lebih optimal secara kecepatan maupun akurasi [18].

Iterasi baru dari keluarga algoritma ini, yaitu YOLOv8, dirilis oleh Ultralytics pada awal tahun 2023 dengan membawa pembaruan signifikan, termasuk penggunaan *anchorless segmentation head* serta optimasi pada struktur jaringan [3]. Secara umum, arsitektur dasar jaringan YOLOv8 terbagi menjadi tiga komponen utama: *Backbone* untuk ekstraksi fitur dari citra masukan, *Neck* untuk melakukan fusi fitur multi-skala, dan *Head* untuk menghasilkan prediksi akhir berupa lokasi, kelas, dan tingkat kepercayaan (*confidence*) dari objek yang dideteksi [3, 1].




Gambar 2.2: Arsitektur Dasar Jaringan YOLOv8 (sumber: Li dkk., 2024 [3])

Algoritma YOLOv8 dirancang dengan tingkat fleksibilitas tinggi dan menyediakan lima varian berdasarkan skala kedalaman (*depth*) dan lebar (*width*) jaringan, yaitu YOLOv8n (nano), YOLOv8s (*small*), YOLOv8m (*medium*), YOLOv8l (*large*), dan YOLOv8x (*extra large*), sebagaimana yang diilustrasikan pada Gambar 2.2 [3]. Mengingat deteksi kerusakan jalan sering kali menuntut implementasi pada perangkat komputasi terbatas, varian yang paling ringan seperti YOLOv8n atau YOLOv8s menjadi kandidat *baseline* yang paling ideal untuk meminimalkan beban komputasi.

2.3 Modifikasi Arsitektur YOLO untuk Efisiensi

Meskipun varian standar YOLOv8 telah memberikan performa yang baik, berbagai modifikasi struktural tingkat lanjut sering kali diperlukan untuk mengatasi tantangan spesifik pada citra jalan raya, seperti ukuran objek kerusakkan yang sangat kecil (*small objects*), latar belakang yang kompleks, serta keterbatasan memori perangkat.

Salah satu teknik modifikasi yang terbukti efektif adalah integrasi mekanisme atensi (*attention mechanism*) ke dalam jaringan [10, 3]. Mekanisme atensi, seperti *Simple, Parameter-Free Attention Module* (SimAM) atau *Convolutional Block Attention Module* (CBAM) [19], berfungsi untuk mengarahkan fokus model secara adaptif pada informasi visual yang krusial (seperti pola retakan tipis) sekaligus menekan gangguan (*noise*) dari elemen visual latar belakang. Modul SimAM, misalnya, mampu menghitung bobot atensi tiga dimensi secara langsung dari fungsi energi neuron tanpa menambah beban parameter jaringan secara signifikan [3].



Gambar 2.3: Contoh Modifikasi Arsitektur YOLOv8 yang Dioptimalkan untuk Efisiensi (sumber: Li dkk., 2024 [3])

Selain mekanisme atensi, efisiensi model juga dapat ditingkatkan melalui

modifikasi pada struktur konvolusi, sebagaimana diilustrasikan pada Gambar 2.3. Penggantian modul konvolusi standar pada bagian *Neck* dengan *Ghost Convolution (GhostConv)* [20] mampu mereduksi redundansi fitur melalui operasi linear berbiaya rendah. Pendekatan ini secara drastis menurunkan jumlah parameter dan beban komputasi (GFLOPs) dengan tetap mempertahankan kemampuan ekstraksi fitur yang tangguh [1, 9].

Di samping optimasi struktural, penyempurnaan pada fungsi kerugian (*loss function*) juga mutlak diperlukan pada tahap pelatihan. Mengingat distribusi data kerusakan jalan (seperti lubang jalan) sering kali mengalami ketimpangan ekstrem (*class imbalance*), fungsi kerugian adaptif seperti *Focal Loss* atau *Refined Generalized Focal Loss* (REG) diterapkan untuk memaksa model memberikan pembobotan penalti yang lebih besar pada kelas minoritas yang sulit dideteksi [12]. Penggabungan teknik atensi, konvolusi ringan, dan fungsi kerugian adaptif ini merupakan landasan utama dalam menghasilkan model deteksi yang komprehensif, efisien, dan siap diimplementasikan secara nyata.

2.4 *Domain Shift* dan Evaluasi *Zero-Shot*

Pengembangan model deteksi kerusakan jalan secara global sering dihadapkan pada masalah *domain shift*, yaitu fenomena penurunan performa drastis ketika model yang dilatih pada dataset suatu wilayah diuji di wilayah lain [11]. Tantangan ini diyakini akan menjadi semakin kompleks ketika sistem deteksi diimplementasikan di Indonesia. Penelitian Hugo dkk. menunjukkan bahwa meskipun model telah dilatih secara spesifik menggunakan dataset jalanan lokal Indonesia, performa deteksinya masih tertahan pada tingkat moderat (F1-Score 59,7%) [4]. Keterbatasan tersebut utamanya dipicu oleh tingginya kompleksitas fitur visual jalanan lokal serta kesulitan model dalam melakukan generalisasi pada data baru (*unseen data*) [4]. Berdasarkan fakta tersebut, penerapan model yang dilatih secara eksklusif menggunakan dataset global, tanpa adanya representasi infrastruktur Indonesia, berpotensi kuat mengalami degradasi akurasi yang jauh lebih drastis akibat eskalasi fenomena *domain shift* [11].

Untuk mengukur ketangguhan model secara objektif dalam menghadapi masalah tersebut, diterapkan skenario pengujian *zero-shot*, yaitu mengevaluasi model yang dilatih pada data global secara langsung pada data primer jalan lokal tanpa melakukan pembelajaran ulang (*fine-tuning*). Pengujian *zero-shot* ini sangat relevan untuk diimplementasikan karena proses pengumpulan dan penganotasian ulang data kerusakan jalan secara spesifik untuk kebutuhan *fine-tuning* membutuhkan waktu yang lama dan sangat menguras tenaga (*time-consuming and labor-intensive*) [13]. Oleh karena itu, evaluasi *zero-shot* menjadi tolok ukur yang paling efisien untuk mengukur kemampuan generalisasi murni dari arsitektur *deep learning* sebelum diterapkan secara nyata pada sistem

pemantauan di Indonesia [3, 1].

2.5 Penelitian Terkait

Penelitian mengenai deteksi kerusakan jalan berbasis *deep learning* telah banyak dilakukan. Beberapa penelitian terdahulu telah mengusulkan berbagai modifikasi arsitektur YOLO maupun penggunaan dataset yang beragam. Meskipun demikian, sebagian besar model masih memiliki keterbatasan ketika dihadapkan pada masalah *domain shift* dan tingginya tingkat *false positive* akibat elemen pengecoh di jalan raya. Rincian perbandingan antara penelitian terdahulu (*state-of-the-art*) dengan rencana penelitian ini dapat dilihat pada Tabel 2.1.

Tabel 2.1: Kekurangan dan Kelebihan Penelitian Deteksi Kerusakan Jalan

Sumber	Metode & Dataset	Kelebihan & Kekurangan
[3]	Metode: RDD-YOLO (YOLOv8 + SimAM + GhostConv) Dataset: RDD2022	Kelebihan: • Mencapai akurasi mAP yang tinggi dengan beban komputasi yang lebih efisien dibandingkan YOLOv8 standar. Kekurangan: • Belum menguji efek <i>domain shift</i> pada jalan di luar 6 negara dataset latih. • Dataset tidak memuat anotasi kelas pengecoh secara spesifik.
[1]	Metode: YOLOv8-PD (YOLOv8n + GhostNet) Dataset: RDD2022	Kelebihan: • Arsitektur sangat ringan, berhasil menekan jumlah parameter komputasi hingga menjadi 2,3 juta parameter. Kekurangan: • Akurasi pada deteksi lubang jalan (D40) anjlok hingga 53,1% dan sering gagal mendeteksi lubang kecil akibat ketimpangan kelas.
[13]	Metode: YOLOv8 Instance Segmentation Dataset: Data Custom Ohio	Kelebihan: • Membuktikan bahwa melatih kelas <i>manhole</i> dan tambalan jalan secara bersamaan terbukti menekan <i>false positive</i>. Kekurangan: • Pengumpulan dan anotasi data mandiri memakan waktu dan membutuhkan komputasi yang sangat besar.

Sumber	Metode & Dataset	Kelebihan & Kekurangan
[4]	Metode: EfficientDet-D0 Dataset: Citra Jalan Indonesia	Kelebihan: • Menggunakan data jalan raya primer (lokal Indonesia) untuk evaluasi dan menggunakan fungsi <i>loss</i> gabungan. Kekurangan: • Performa akurasi tertahan pada tingkat moderat (F1-Score 59,7%) karena kesulitan model melakukan generalisasi fitur lokal.
[9]	Metode: YOLO-LWD (GhostConv + ECA) Dataset: Aug-RDD	Kelebihan: • Model sangat efisien secara komputasi dan menganotasi penutup saluran (<i>manhole</i>) secara terpisah sebagai pengecoh. Kekurangan: • Hanya divalidasi pada <i>single domain</i> (jalan lokal Tiongkok), belum dievaluasi kemampuannya di negara lain.
Usulan	Metode: Evaluasi Komparatif YOLO <i>lightweight</i> Dataset: N-RDD2024 & Jalan Raya Indonesia	Kelebihan Rencana Penelitian: • Menggabungkan dataset global N-RDD2024 (dengan anotasi kelas pengecoh eksplisit) dan mengujinya secara <i>zero-shot</i> langsung pada jalan Indonesia.

Berdasarkan Tabel 2.1, terlihat bahwa sebagian besar model yang berkinerja tinggi dikembangkan menggunakan dataset global (seperti RDD2022) yang tidak mencakup kelas pengecoh secara eksplisit [3, 1]. Di sisi lain, penelitian yang telah menyoroti pentingnya kelas pengecoh seperti *manhole* dan tambalan aspal masih dievaluasi pada lingkungan yang terbatas (*single domain*) [13, 9]. Sementara itu, implementasi model deteksi secara langsung di Indonesia masih menunjukkan performa yang tertahan akibat kompleksitas fitur jalanan lokal [4]. Oleh karena itu, penelitian Tugas Akhir ini diusulkan untuk mengisi kesenjangan (*research gap*) tersebut secara sistematis dengan melakukan evaluasi komparatif arsitektur YOLO *lightweight* menggunakan dataset N-RDD2024, serta mengukur ketangguhan generalisasinya secara *zero-shot* di domain jalan raya Indonesia.

Bab III

Metodologi dan Desain Sistem

3.1 Eksplorasi Data

Eksplorasi data (*Exploratory Data Analysis* / EDA) pada penelitian ini dilakukan untuk memahami karakteristik, distribusi, dan kualitas visual dari citra kerusakan jalan. Melalui analisis statistik dan visualisasi, EDA berperan penting dalam mengidentifikasi ketidakseimbangan kelas (*class imbalance*) dan variasi ukuran objek untuk menentukan strategi pra-pemrosesan data yang tepat.

3.1.1 Akuisisi Dataset


Penelitian ini menggunakan dua jenis dataset yang diperoleh melalui metode akuisisi yang berbeda untuk memenuhi skenario pelatihan dan pengujian *zero-shot*:

1. **Data Sekunder (Dataset Pelatihan):** Dataset global [N-RDD2024](#) yang merupakan perluasan dari RDD2022. Dari dataset ini, diekstraksi subset spesifik dari negara Asia (India, China, dan Jepang) dengan total 10.395 citra. Data ini sudah memiliki anotasi *bounding box* untuk kelas kerusakan utama (D00, D10, D20, D40) serta kelas pengecoh (D70 untuk *manhole* dan D80 untuk tambalan jalan).
2. **Data Primer (Dataset Pengujian *Zero-Shot*):** Data citra jalan raya primer yang diakuisisi secara mandiri di wilayah Bandung, Indonesia. Pengambilan data dilakukan pada kondisi siang hari untuk menjaga konsistensi pencahayaan. Akuisisi dilakukan menggunakan perangkat HP Infinix Note 50 (kamera 50 MP) dengan konfigurasi perekaman 1080p pada 30 fps, dan posisi kamera merepresentasikan sudut pandang pengendara (*point-of-view*) dari kendaraan roda dua. Karena data ini bersifat mentah, dilakukan pelabelan secara manual menggunakan perangkat lunak *Computer Vision Annotation Tool* (CVAT) / Roboflow dengan format anotasi standar YOLO.

3.1.2 Visualisasi Data

Tahap eksplorasi dan visualisasi data pada penelitian ini difokuskan pada subset data latih (*training set*) N-RDD2024 dari tiga negara Asia: Jepang, Tiongkok, dan India. Mengingat dataset N-RDD2024 awalnya dikembangkan untuk keperluan kompetisi dengan label *ground truth* pada data uji (*test set*) yang dirahasiakan, maka seluruh proses eksplorasi ini hanya menggunakan data latih publik.

Dari total 10.395 citra awal, dilakukan proses penyaringan (*filtering*) untuk mengekstraksi citra yang hanya memuat setidaknya satu dari enam kelas target penelitian (retakan memanjang, retakan melintang, retakan buaya, lubang jalan, penutup saluran/ *manhole*, dan jalan bertambal). Proses penyaringan ini menghasilkan 9.670 citra siap pakai yang secara asli telah tersedia dalam format resolusi 640×640 piksel. Proporsi distribusi citra berdasarkan negara ditunjukkan pada Gambar 3.1.




Gambar 3.1: Distribusi Citra N-RDD2024 Berdasarkan Negara

Berdasarkan Gambar 3.1, terlihat bahwa dataset didominasi oleh citra dari Jepang sebanyak 6.638 citra (68,6%), disusul oleh Tiongkok dengan 1.977 citra (20,4%), dan India dengan 1.055 citra (10,9%). Keragaman asal citra ini memunculkan variasi visual yang tinggi pada karakteristik jalan, sebagaimana divisualisasikan pada contoh citra anotasi kelas dan contoh perwakilan tiap negara di Gambar 3.2 dan Gambar 3.3.




Gambar 3.2: Contoh Visualisasi *Bounding Box* untuk Enam Kelas Target




Gambar 3.3: Contoh Perbedaan Karakteristik Citra Jalan di tiap Negara

Selain asal negara, tantangan utama dari dataset ini terletak pada ketimpangan distribusi jumlah objek antar kelas (*class imbalance*). Analisis terhadap total 24.290 objek berlabel menunjukkan bahwa kelas retakan struktural sangat mendominasi dibandingkan kelas anomali permukaan lainnya.



Gambar 3.4: Distribusi Jumlah Objek Berdasarkan Kelas pada Dataset Tersaring

Merujuk pada Gambar 3.4, retakan memanjang dan retakan buaya secara berurutan mencatatkan jumlah terbanyak, yaitu 6.447 dan 6.272 objek. Sebaliknya, kelas jalan bertambal (*patchy road*) sangat langka dengan hanya 672 objek. Kelas lubang jalan (*pothole*) dan *manhole* juga berada pada kategori minoritas (masing-masing 3.101 dan 3.236 objek). Ketimpangan ini semakin terlihat kompleks ketika dibedah berdasarkan sebaran tiap negara, seperti yang disajikan pada Gambar 3.5.




Gambar 3.5: Sebaran Jumlah Objek Spesifik per Kelas di Masing-masing Negara

Data dari Gambar 3.5 menyoroti anomali distribusi lokal. Sebagai contoh, sebagian besar objek *manhole* (3.051 dari 3.236 objek) secara eksklusif bersumber dari Jepang, sementara objek lubang jalan (*pothole*) memiliki proporsi kemunculan yang cukup tinggi di India (994 objek dari total 1.055 citra India) dibandingkan negara lainnya. Fakta empiris terkait ketimpangan kelas yang ekstrem ini menjustifikasi perlunya penerapan modifikasi struktural dan fungsi kerugian adaptif, seperti *Focal*

Loss, guna mencegah model bias terhadap kelas mayoritas (retakan) dan mengabaikan objek minoritas (lubang dan pengecoh).

Analisis komprehensif terhadap 24.290 kotak pembatas (*bounding box*) pada dataset tersaring dilakukan untuk melihat proporsi luas objek relatif terhadap luas total citra. Hasil dari analisis metrik tersebut divisualisasikan melalui histogram pada Gambar 3.6.




Gambar 3.6: Distribusi Persentase Luas *Bounding Box* Terhadap Luas Citra

Berdasarkan Gambar 3.6, distribusi persentase luas *bounding box* menunjukkan kecondongan positif yang sangat ekstrem (*highly right-skewed*). Nilai median tercatat pada angka 1,69%, yang mengindikasikan bahwa separuh dari total keseluruhan objek target pada dataset berukuran kurang dari 1,7% dari total keseluruhan area piksel gambar. Lebih lanjut, metrik persentil ke-90 (P90) yang hanya menyentuh angka 17,19% menegaskan bahwa keberadaan objek kerusakan berukuran besar sangat jarang ditemukan di lapangan.

Banyaknya objek berukuran sangat kecil dalam dataset ini menjadi tantangan visual tersendiri. Ukuran target yang minim, ditambah dengan tekstur latar belakang jalan raya yang kompleks, membuat anomali tersebut secara alami lebih sulit untuk dikenali secara akurat dalam proses deteksi.

3.2 Alur Penelitian

Penelitian ini dilaksanakan berdasarkan alur penelitian yang dirancang secara terstruktur dan sistematis. Rangkaian tahapan dari proses akuisisi data hingga penarikan kesimpulan divisualisasikan pada diagram alir (*flowchart*) di Gambar 3.7.



Gambar 3.7: Flowchart Alur Penelitian

Penelitian dimulai dengan pengumpulan data yang terbagi menjadi dua domain utama. Pertama, akuisisi data sekunder menggunakan dataset global [N-RDD2024](#) yang memiliki label kelas kerusakan dan kelas pengecoh secara komprehensif [14]. Kedua, akuisisi data primer berupa citra jalan raya lokal di Bandung yang diambil secara mandiri. Karena data primer yang terkumpul masih bersifat mentah, maka dilakukan proses pelabelan secara manual dengan memberikan kotak pembatas (*bouding box*) menggunakan format anotasi standar YOLO agar sesuai dengan kebutuhan inferensi model nantinya.

Setelah data terkumpul, tahap selanjutnya adalah Eksplorasi Data (*Exploratory Data Analysis* / EDA) untuk menganalisis distribusi kelas, ketimpangan data, serta variasi ukuran anomali permukaan jalan. Pemahaman terhadap karakteristik data ini menjadi landasan untuk membagi dataset sekunder (*data splitting*) menjadi himpunan data latih (*train*), data validasi (*validation*), dan data uji (*test*) dengan proporsi 70:20:10.

Himpunan data tersebut kemudian melalui tahap pra-pemrosesan (*preprocessing*). Tahap ini difokuskan pada penyesuaian resolusi citra (*resizing*) menjadi 640×640 piksel agar sesuai dengan standar ukuran arsitektur masukan (*input size*) keluarga algoritma YOLO [1]. Selanjutnya, dilakukan normalisasi nilai piksel serta penerapan teknik augmentasi data seperti *Mosaic*. Augmentasi *Mosaic* bekerja dengan cara menggabungkan empat citra berbeda menjadi satu masukan tunggal, yang secara


efektif memperkaya variasi fitur spasial dan melatih model untuk lebih kebal terhadap latar belakang yang kompleks serta variasi skala objek [1].

Tahap pemodelan merancang tiga skenario eksperimen komparatif. Skenario pertama adalah pelatihan model *baseline* menggunakan varian YOLOv8n. Skenario kedua merupakan pelatihan model eksperimen menggunakan arsitektur YOLO yang dimodifikasi (seperti penyisipan mekanisme atensi dan konvolusi ringan yang merujuk pada literatur referensi [3, 1]). Skenario ketiga menggunakan iterasi algoritma YOLO versi terbaru. Skenario ketiga ini sangat krusial untuk mengevaluasi dan membandingkan apakah peningkatan arsitektur bawaan (*native*) dari versi mutakhir mampu memberikan performa yang lebih tangguh dibandingkan dengan harus merancang modifikasi struktural pada iterasi YOLO sebelumnya.

Ketiga skenario model tersebut kemudian dievaluasi menggunakan metrik performa deteksi dan metrik efisiensi komputasi untuk menentukan arsitektur dengan keseimbangan kinerja terbaik. Sebagai puncak dari pengujian, model terbaik yang diperoleh dari pelatihan data sekunder akan langsung diuji kemampuannya dalam melakukan generalisasi (*zero-shot inference*) menggunakan dataset primer jalan raya lokal. Uji inferensi ini dilakukan tanpa melatih ulang (*fine-tuning*) model pada data primer, guna mengukur secara objektif ketangguhan arsitektur dalam menghadapi fenomena *domain shift*. Penelitian diakhiri dengan analisis hasil komprehensif atas inferensi *zero-shot* dan penarikan kesimpulan.

3.3 Rancangan Arsitektur Model

Algoritma deteksi objek berbasis keluarga YOLO beroperasi sebagai detektor satu tahap (*one-stage detector*) yang memproses citra secara serentak (*end-to-end*). Pada tahap awal, citra masukan dibagi ke dalam kisi spasial (*grid*) berukuran $S \times S$. Setiap sel pada kisi tersebut secara independen bertanggung jawab untuk memprediksi kotak pembatas (*bounding box*) beserta probabilitas kelas dari objek yang pusat lokasinya jatuh di dalam area sel tersebut [3, 8]. Alur kerja dan topologi dasar dari rancangan arsitektur ini divisualisasikan pada Gambar 3.8.



Gambar 3.8: Ilustrasi Alur Kerja dan Arsitektur Dasar Jaringan YOLO

Secara struktural, rancangan implementasi model jaringan YOLO pada penelitian

ini bertumpu pada tiga komponen arsitektur utama, yaitu:

1. **Backbone:** Berfungsi sebagai pengekstraksi fitur utama dari citra masukan. Pada iterasi arsitektur mutakhir seperti YOLOv8, komponen ini memanfaatkan kombinasi modul konvolusi standar (Conv), modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*) untuk memastikan aliran gradien yang kaya dan efisien selama propagasi balik, serta *Spatial Pyramid Pooling - Fast* (SPPF) untuk mengekstrak fitur pada berbagai skala abstraksi spasial [3, 1]. Untuk meningkatkan sensitivitas terhadap objek berukuran kecil (seperti retakan halus), komponen *backbone* ini sering kali menjadi target utama penyisipan mekanisme atensi, seperti modul SimAM [3] maupun SOM [8].
2. **Neck:** Bertugas melakukan fusi fitur multi-skala. Melalui hierarki operasi *Upsample* dan penggabungan (*Concatenation*), bagian ini memadukan peta fitur beresolusi tinggi (yang kaya akan detail spasial) dengan peta fitur beresolusi rendah (yang kaya akan informasi semantik global) [3, 9]. Fusi ini memungkinkan model untuk secara adaptif mengenali objek kerusakan jalan dalam rentang skala yang bervariasi. Pada implementasi model modifikasi (*lightweight*), modul konvolusi standar pada *Neck* umumnya digantikan oleh operasi linear hemat biaya seperti *Ghost Convolution* guna mereduksi beban komputasi (GFLOPs) dan menekan redundansi parameter secara drastis [3, 1, 9].
3. **Head:** Merupakan komponen akhir jaringan yang mengadopsi struktur *decoupled head* untuk memisahkan tugas klasifikasi dan pelokalisasi secara independen. Bagian ini memproses fitur hasil fusi dari *Neck* guna menghasilkan keluaran prediksi secara paralel, yaitu koordinat kotak pelingkup (*bounding boxes*), tingkat metrik keyakinan (*confidence score*), dan probabilitas kelas (*class probability map*) [3, 9]. Prediksi mentah yang saling tumpang tindih kemudian disaring melalui algoritma *Non-Maximum Suppression* (NMS) untuk menghasilkan keputusan deteksi akhir yang tunggal dan presisi.

3.4 Evaluasi Performa Model

Evaluasi kinerja model pada penelitian ini dibagi menjadi dua aspek utama, yaitu evaluasi ketepatan deteksi (akurasi) dan evaluasi efisiensi komputasi model. Metrik-metrik ini krusial untuk mengukur keberhasilan model, terutama ketika diimplementasikan pada skenario *real-time* dan perangkat dengan sumber daya terbatas [10].

3.4.1 *Confusion Matrix* (TP, FP, FN)

Dalam tugas deteksi objek, landasan utama perhitungan metrik evaluasi bersumber dari *Confusion Matrix* yang didefinisikan berdasarkan ambang batas *Intersection over Union* (IoU). Matriks ini mengelompokkan hasil prediksi ke dalam tiga kondisi [3, 1]:

- **True Positive (TP):** Model berhasil memprediksi objek kerusakan jalan dengan benar, kelasnya sesuai dengan *ground truth*, dan nilai IoU melampaui ambang batas yang ditentukan (misalnya $\text{IoU} > 0,5$).
- **False Positive (FP):** Model mendeteksi adanya objek kerusakan jalan di lokasi tertentu, padahal pada kondisi asli (*ground truth*) tidak terdapat kerusakan (salah deteksi) atau kelas yang diprediksi keliru.
- **False Negative (FN):** Terdapat kerusakan jalan pada kondisi nyata, namun model gagal mendeteksi atau melokalisasi kerusakan tersebut (*missed detection*).

3.4.2 *Precision, Recall, dan F1-Score*

Berdasarkan nilai TP, FP, dan FN, kinerja klasifikasi model dapat diukur menggunakan tiga metrik turunan. *Precision* mengukur tingkat ketepatan prediksi positif dari model, sedangkan *Recall* (sensitivitas) mengukur kemampuan model dalam menemukan seluruh objek kerusakan yang sebenarnya ada di dalam citra [1, 3].

$$Precision = \frac{TP}{TP + FP} \quad (3.1)$$

$$Recall = \frac{TP}{TP + FN} \quad (3.2)$$

Karena *Precision* dan *Recall* sering kali berbanding terbalik, digunakan metrik *F1-Score* yang merupakan rata-rata harmonis dari keduanya. Metrik ini memberikan penilaian yang seimbang dan komprehensif terkait ketangguhan model [3].

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.3)$$

3.4.3 *Intersection over Union (IoU) dan Mean Average Precision (mAP)*

Intersection over Union (IoU) mengukur seberapa akurat lokalisasi kotak pembatas (*bounding box*) yang diprediksi oleh model dibandingkan dengan kotak pembatas asli (*ground truth*) [3].

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}} \quad (3.4)$$

Dari perhitungan presisi pada berbagai ambang batas *Recall*, diperoleh nilai *Average Precision* (AP). Rata-rata AP dari seluruh kelas objek kemudian dirumuskan menjadi *Mean Average Precision* (mAP), yang merupakan metrik standar tertinggi dalam deteksi objek [10, 3]:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (3.5)$$

Dalam penelitian ini, selain menggunakan metrik $\text{mAP}@0.5$ (mAP pada IoU 50%), digunakan pula metrik evaluasi multi-skala seperti mAP_s (untuk objek berukuran

sangat kecil $< 32 \times 32$ piksel), mAP_m (skala menengah), dan mAP_l (skala besar) untuk menganalisis sensitivitas model terhadap variasi ukuran retakan jalan yang ekstrem [8].

3.4.4 Metrik Efisiensi Komputasi

Untuk mengukur kelayakan model agar dapat dideploy pada perangkat komputasi bergerak (*mobile terminal devices*), digunakan tiga metrik evaluasi efisiensi [10, 8]:

- **Parameters (Params):** Total kuantitas bobot yang dapat dipelajari (*learnable parameters*) dalam jaringan saraf. Metrik ini, biasanya dalam satuan *Million* (M), mengukur kompleksitas spasial dan ukuran ruang penyimpanan model.
- **GFLOPs (*Giga Floating-Point Operations Per Second*):** Kuantitas operasi komputasi yang dibutuhkan model dalam satu kali inferensi. Metrik ini secara langsung merepresentasikan beban komputasi jaringan.
- **FPS (*Frames Per Second*):** Indikator langsung dari kecepatan inferensi model dalam memproses citra per detik, yang menentukan kelayakan sistem untuk skenario pengawasan *real-time* [10].

3.5 Skenario Penelitian

Skenario pengujian merupakan inti eksperimental dari metodologi penelitian ini. Untuk menjawab ketiga rumusan masalah yang telah ditetapkan pada Bab 1 secara sistematis, skenario penelitian ini dipecah ke dalam tiga tahapan evaluasi utama:

3.5.1 Skenario 1: Evaluasi Kinerja pada Domain Sumber dan Analisis Kelas Pengecoh

Skenario pertama dirancang untuk melatih dan mengevaluasi ketiga arsitektur model (YOLOv8n *baseline*, YOLO Modifikasi, dan YOLO Terbaru) menggunakan dataset sekunder N-RDD2024. Fokus utama pada tahap ini adalah mengukur tingkat akurasi (mAP) dari masing-masing arsitektur dalam mendeteksi kelas kerusakan jalan utama. Bersamaan dengan itu, evaluasi juga diarahkan untuk mengamati bagaimana model menangani ketimpangan data (*class imbalance*) serta kemampuannya dalam membedakan kerusakan jalan asli dari kelas pengecoh seperti penutup saluran air (D70) dan tambalan aspal (D80) [14]. Kemampuan arsitektur dalam menghindari kebingungan visual terhadap objek pengecoh ini akan dibuktikan secara empiris melalui analisis matriks kebingungan (*Confusion Matrix*) guna melihat tingkat penekanan *false positive* [13]. Untuk memastikan model tidak bias terhadap kelas mayoritas selama proses pelatihan berlangsung, fungsi kerugian (*loss function*) adaptif seperti *Focal Loss* turut diterapkan [1, 12]. Skenario ini akan menghasilkan capaian metrik mAP dan F1-Score murni pada domain sumber yang menjadi *benchmark* performa model.

3.5.2 Skenario 2: Analisis Keseimbangan Kinerja (*Trade-Off*) dan Kelayakan *Real-Time*

Skenario kedua berfokus pada analisis kelayakan penerapan model pada skenario *real-time* dengan sumber daya komputasi terbatas. Pada tahap ini, metrik akurasi (mAP) dari model-model yang telah dilatih pada Skenario 1 akan dibandingkan dengan metrik efisiensi komputasinya, yang meliputi kecepatan inferensi (FPS), jumlah parameter (*Params*), dan beban operasi (*GFLOPs*). Analisis keseimbangan kinerja (*trade-off*) ini akan menentukan apakah modifikasi arsitektur *lightweight* benar-benar mampu memberikan titik optimal terbaik antara menekan beban komputasi secara signifikan tanpa mengorbankan ketepatan deteksi. Dari skenario evaluasi komputasi ini, akan dipilih satu model terbaik untuk dilanjutkan ke tahap evaluasi akhir.

3.5.3 Skenario 3: Uji Ketangguhan Lintas Domain (*Zero-Shot Inference*)

Skenario ketiga bertujuan untuk mengukur secara kuantitatif tingkat kesenjangan domain (*domain gap*) dari model terbaik yang telah terpilih. Model terbaik dari hasil analisis komputasi Skenario 2 akan diekstraksi bobotnya (*weights*) dan diuji secara langsung (*zero-shot*) menggunakan dataset primer jalan raya Bandung, tanpa memberikan model kesempatan untuk melakukan *fine-tuning*. tahap evaluasi akhir ini akan membuktikan kemampuan generalisasi murni model dalam menghadapi data baru (*unseen data*). Perbedaan selisih akurasi (*accuracy drop*) antara kinerja di Skenario 1 dan Skenario 3 akan dianalisis sebagai representasi besaran *domain shift*.

Daftar Pustaka

- [1] Jiayi Zeng and Han Zhong. Yolov8-pd: an improved road damage detection algorithm based on yolov8n model. *Scientific Reports*, 14(1), 2024. Cited by: 83; All Open Access, Gold Open Access, Green Open Access.
- [2] Stefania Corinthia Radopoulou and Ioannis Brilakis. Detection of multiple road defects for pavement condition assessment. *Transportation Research Record: Journal of the Transportation Research Board*, 2486:101–109, 2015.
- [3] Yue Li, Chang Yin, Yutian Lei, Jiale Zhang, and Yiting Yan. Rdd-yolo: Road damage detection algorithm based on improved you only look once version 8. *Applied Sciences (Switzerland)*, 14(8), 2024. Cited by: 52; All Open Access, Gold Open Access, Green Open Access.
- [4] Bernard Hugo, Alfi Yusrotis Zakiyyah, and Kelvin Asclepius Minor. EfficientDet model for accurate detection and classification of road damages in Indonesia. *Journal of Machine Learning and Deep Learning (JMLDL)*, 2(1):11–17, June 2025.
- [5] Hendra Kusumah, Mohamad Riski Nurholik, Catur Putri Riani, and Ilham Riyan Nur Rahman. Deep learning for pothole detection on Indonesian roadways. *Jurnal Sensi: Strategic of Education in Information System*, 9(2):175–186, 2023.
- [6] Seyed Amirhossein Hosseini and Omar Smadi. How prediction accuracy can affect the decision-making process in pavement management system. *Infrastructures*, 6(2):28, 2021.
- [7] Vishal Mandal, Abdul Rashid Mussah, and Yaw Adu-Gyamfi. Deep learning frameworks for pavement distress classification: A comparative analysis. In *2020 IEEE International Conference on Big Data (Big Data)*, pages 5577–5583, 2020.
- [8] Wei Wang, Xiaoru Yu, Bin Jing, Ziqi Tang, Wei Zhang, Shengyu Wang, Yao Xiao, Shu Li, and Liping Yang. Yolo-rd: A road damage detection method for effective pavement maintenance. *Sensors*, 25(5), 2025. Cited by: 12; All Open Access, Gold Open Access, Green Open Access.
- [9] Xiaohui Shi. A lightweight road damage detection model based on structural improvement and knowledge distillation. *International Core Journal of Engineering*, 12(3):148–155, Mar. 2026.

- [10] Chenguang Wu, Min Ye, Jiale Zhang, and Yuchuan Ma. Yolo-lwnet: A lightweight road damage object detection network for mobile terminal devices. *Sensors*, 23(6), 2023. Cited by: 52; All Open Access, Gold Open Access, Green Open Access.
- [11] Deeksha Arya, Hiroya Maeda, Sanjay Kumar Ghosh, Durga Toshniwal, and Yoshihide Sekimoto. Rdd2022: A multi-national image dataset for automatic road damage detection. *Geoscience Data Journal*, 11(4):846 – 862, 2024. Cited by: 158; All Open Access, Gold Open Access, Green Open Access.
- [12] Teerapong Panboonyuen. Reg: Refined generalized focal loss for road asset detection on thai highways using vision models. In *2025 17th International Conference on Knowledge and Smart Technology (KST)*, pages 324–329. IEEE, 2025.
- [13] Younis Matouq, Dmitry Manasreh, and Munir D Nazzal. Ai-driven approach for automated real-time pothole detection, localization, and area estimation. *Transportation Research Record*, 2678(11):2018–2031, 2024.
- [14] Ömer Kaya and Muhammed Yasin Codur. N-rdd2024: Road damage and defects, 2024.
- [15] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 779–788, 2016.
- [16] Joseph Redmon and Ali Farhadi. Yolo9000: better, faster, stronger. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7263–7271, 2017.
- [17] Joseph Redmon and Ali Farhadi. Yolov3: An incremental improvement. *arXiv preprint arXiv:1804.02767*, 2018.
- [18] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. Yolov4: Optimal speed and accuracy of object detection. *arXiv preprint arXiv:2004.10934*, 2020.
- [19] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module. In *Proceedings of the European conference on computer vision (ECCV)*, pages 3–19, 2018.
- [20] Kai Han, Yunhe Wang, Qi Tian, Jianyuan Guo, Chunjing Xu, and Chang Xu. Ghostnet: More features from cheap operations. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 1580–1589, 2020.

Lampiran